



Plataforma Modular de Inteligencia de Compras y Surtido

Propuesta de Arquitectura Técnica

Capa transversal (Data Analytics Foundation)

Principios Generales de Arquitecturas Modernas de Datos

Las arquitecturas modernas de datos buscan separar la captura operativa de la explotación analítica. En lugar de consultar directamente los sistemas transaccionales para cada análisis, se publican datos autorizados, se organizan en estructuras analíticas y se procesan con servicios especializados. Esto permite proteger la operación diaria, reducir acoplamientos técnicos y convertir la información existente en activos reutilizables para múltiples decisiones de negocio.

Un principio clave es la separación entre almacenamiento y procesamiento. El almacenamiento conserva la información de forma segura, trazable y escalable; el procesamiento se activa únicamente cuando se requiere transformar, calcular, consultar o ejecutar una lógica analítica. Esta separación evita mantener capacidad de cómputo encendida de manera permanente y permite que cada componente crezca de acuerdo con su uso real.

También se prioriza el uso de servicios administrados y bajo demanda. Esto significa utilizar componentes que no requieran administrar servidores de forma tradicional y que puedan ejecutarse por calendario, por evento o por solicitud. Este enfoque es especialmente importante porque permite validar el valor del caso de uso sin asumir desde el inicio una infraestructura grande, permanente o costosa.

Bajo esta lógica, la arquitectura debe ser proporcional al problema, pero no limitada en su evolución. Los datos se exponen mediante contratos claros, se resguardan con controles de seguridad y mínimo privilegio, se documentan con trazabilidad y se preparan para que puedan reutilizarse en nuevos análisis. Así, la capa transversal de datos puede iniciar con una base acotada y, al mismo tiempo, dejar fundamentos para crecer hacia capacidades más amplias cuando el volumen, la madurez o las necesidades del negocio lo justifiquen.


La propuesta de arquitectura de datos en Azure se basa en estos principios. No pretende construir una plataforma corporativa completa antes de generar valor, sino aplicar buenas prácticas modernas, seguridad, desacoplamiento, almacenamiento escalable, procesamiento bajo demanda, observabilidad y reutilización para los análisis ya creados en el levantamiento del proyecto.


Arquitectura Propuesta en Azure

Para el crear la capa transversal de datos se propone una arquitectura escalable, serverless y proporcional sobre Azure. Su propósito es conectar de forma segura con las vistas autorizadas del ERP, conservar la información necesaria en un repositorio analítico ligero, ejecutar el motor y habilitar su consumo sin desplegar desde el inicio una plataforma corporativa de datos ni una arquitectura Medallion completa.

Premisas de arquitectura

- **Mínima intrusión y mínimo privilegio:** el ERP se consulta mediante vistas autorizadas y un usuario de solo lectura; no se exponen tablas operativas completas ni información que no requiera.
- **Salida controlada con IP fija:** la conectividad desde Azure podrá autorizarse mediante una IP estable, reglas de firewall y credenciales protegidas.
- **Procesamiento proporcional:** la extracción y el cálculo se ejecutan por calendario o bajo demanda, evitando infraestructura encendida de forma permanente cuando no existe actividad.
- **Almacenamiento analítico ligero:** Azure Data Lake Storage Gen2 o un servicio equivalente conservará trazabilidad, datasets listos para el motor, resultados y controles sin duplicar capas innecesarias.
- **Consumo desacoplado del formato:** la aplicación, una herramienta de consulta o una salida ejecutiva consumirán el mismo resultado estructurado; el formato final se define durante el diseño.
- **Base para evolución futura:** los activos construidos podrán reutilizarse para análisis adicionales, pero el alcance presente se mantiene centrado en el motor de decisión comercial.





Detalle de la Arquitectura

La solución se divide en componentes simples para mantener seguridad, trazabilidad y flexibilidad. Esta modularidad no implica construir múltiples capas empresariales: cada componente existe porque resuelve una necesidad concreta y puede evolucionar o sustituirse sin rehacer el motor completo.

1. ERP y vistas analíticas autorizadas

La fuente inicial es el SQL Server asociado al ERP. A nivel operativo ya se revisaron con los equipos los dominios de información necesarios y su utilidad para la evaluación comercial. El pendiente de la etapa técnica será mapear cada concepto a tablas, campos, llaves, historia y granularidad reales. El acceso se realizará sobre vistas aprobadas que reduzcan columnas, filtren información no necesaria y encapsulen reglas de extracción, evitando exponer directamente los objetos transaccionales.

- **Modo de acceso:** usuario de solo lectura con privilegios mínimos y trazabilidad de consultas.
- **Frecuencia inicial:** procesamiento batch o bajo demanda; el incremental se utilizará cuando existan marcas de actualización confiables.

Objetivo: obtener un contrato de datos estable y seguro entre el ERP y el motor, sin afectar la operación productiva.

2. Conectividad y seguridad de red

La comunicación desde Azure hacia el SQL Server on-premise se plantea mediante una red virtual en Azure y una IP pública fija de salida. Esta IP puede ser agregada a una lista autorizada por el equipo de seguridad de Super Naturista, permitiendo una comunicación controlada y trazable.

- **Azure VNet / Subnet:** crea un perímetro lógico para ubicar los servicios que requieren conectividad controlada.
- **NAT Gateway + Static Public IP:** proporciona una salida estable hacia internet o redes corporativas, facilitando reglas de firewall del lado on-premise.
- **Azure Key Vault:** resguarda credenciales y secretos para evitar que queden expuestos en código, archivos o repositorios.

3. Extracción y sincronización de datos

La extracción centraliza únicamente la información publicada por las vistas autorizadas. El proceso podrá ejecutarse por lotes y conservará conteos, fechas de corte y referencias al origen para que cada evaluación sea reproducible. El proyecto no requiere tiempo real, la frecuencia se definirá según el proceso comercial y la capacidad técnica del ERP.

Cuando las fuentes tengan marcas confiables de creación o actualización se aplicarán incrementales. Para entidades pequeñas o fuentes sin controles adecuados podrán utilizarse refrescos completos, ventanas móviles o snapshots. La estrategia se confirmará durante el mapeo técnico y podrá variar por dominio.

El principio rector es extraer menos, con mayor claridad: solo los datos necesarios para enlazar, comparar, medir y formular la evaluación.

4. Repositorio analítico

El repositorio central se propone como la capa de almacenamiento de la arquitectura. Su función será conservar de forma segura y ordenada la información autorizada, incluyendo extractos de origen, datasets listos para el motor, resultados calculados y controles de ejecución. Para este alcance, la organización será compacta y enfocada en la decisión comercial, evitando introducir conceptos arquitectónicos adicionales que puedan interpretarse como una plataforma amplia o compleja.

Zona lógica	Propósito funcional
Trazabilidad de origen	Extractos autorizados, fecha de corte, referencia a la vista y controles para reconstruir qué información utilizó una evaluación.
Datasets analíticos	Productos, ventas, precios, costos, inventario, compras, proveedores, canales, calendario y métricas en el nivel exacto requerido por el motor.
Resultados del motor	Candidatos, productos comparables, métricas, score, confianza, riesgos, razones y recomendación sugerida.
Control operativo	Watermarks, bitácoras, conteos, validaciones, parámetros y versiones de reglas.

Esta organización permite que los datos y el motor evolucionen juntos. Cada dominio se incorpora cuando sus vistas, llaves y reglas han sido validadas, y el mismo ciclo se utiliza para probar comparables, métricas y recomendaciones.

La organización lógica recomendada se resume en cuatro zonas: trazabilidad de origen, datasets analíticos, resultados del motor y control operativo.

5. Orquestación, control y observabilidad

Todas las tareas deberán ejecutarse de forma controlada y trazable. Para ello se recomienda registrar watermarks, bitácoras de ejecución, conteos de registros, errores y tiempos de procesamiento. Esta información permite saber cuándo corrió el proceso, qué datos tomó y si la ejecución fue exitosa.

- **Azure Table Storage o archivos de control:** almacenamiento ligero para watermarks, logs operativos y configuración simple.
- **Azure Monitor / Log Analytics:** monitoreo de ejecuciones, errores y eventos relevantes del proceso.

Servicios Propuestos y Fundamento Arquitectónico

Con base en la información requerida ya revisada durante el discovery operativo, y considerando los principios de arquitectura de datos descritos previamente, se propone la siguiente arquitectura técnica de referencia en Azure. La tabla resume los servicios considerados para habilitar la capa transversal de datos, buscando utilizar componentes administrados, de bajo mantenimiento y con pago principalmente por uso. La selección final de servicios se confirmará durante el mapeo técnico y la validación de capacidades existentes de Super Naturista.

Servicio de referencia	Descripción funcional	Fundamento arquitectónico
Azure VNet / Subnet	Perímetro lógico para componentes que requieren conectividad controlada.	Aislamiento y base para salida segura hacia el entorno on-premise.
NAT Gateway + IP pública fija	Salida estable desde Azure hacia las vistas del ERP.	Permite autorización de una IP única y reglas trazables de firewall.
Azure Key Vault	Protección de credenciales, secretos y cadenas de conexión.	Evita secretos en código y soporta privilegios mínimos.
Azure Container Apps Job o equivalente	Ejecución programada o bajo demanda de extracción y motor.	Cómputo efímero, flexible y de bajo mantenimiento.
Azure Data Lake Storage Gen2	Persistencia de trazabilidad, datasets analíticos, resultados y controles.	Almacenamiento escalable sin obligar a construir múltiples capas.
Azure Table Storage o archivos de control	Watermarks, logs, configuración y versiones de reglas.	Control operativo ligero.
Servicio de consulta serverless	Exposición SQL o equivalente sobre los datasets del repositorio.	Consumo bajo demanda sin un Data Warehouse dedicado encendido.
Aplicación / herramienta analítica aprobada	Captura de candidatos y presentación de resultados.	El formato de salida se definirá durante el diseño.
Servicio LLM opcional	Interpretación en lenguaje de negocio de resultados ya calculados.	No sustituye reglas, score ni aprobación.

Fundamento de estimación de costos

El costo de nube se estimará con base en el volumen real de datos, frecuencia de ejecución, tiempo de procesamiento, almacenamiento histórico, consultas sobre la información del repositorio y consumo de visualizaciones o IA. El objetivo de iniciar con esta arquitectura es evitar costos asociados a servidores, capacidad dedicada o componentes permanentes que permanezcan encendidos aun cuando no hay procesamiento activo.

Componente	Cómo se genera costo	Consideración
Cómputo	Tiempo de ejecución, memoria y CPU.	Los procesos corren por calendario o bajo demanda y se detienen al finalizar.
Almacenamiento	GB almacenados y operaciones de lectura/escritura.	El volumen inicial se limita a los datasets requeridos por el motor.
Consulta analítica	Datos leídos o procesados por el servicio de consulta.	Se publicarán datasets optimizados y resultados listos para consumo.
Red / conectividad	Uso de NAT Gateway, IP pública y tráfico procesado.	Se justifica por control de seguridad y conectividad autorizada.
Monitoreo	Logs ingeridos y retención.	Retención acotada y suficiente para auditoría.
IA interpretativa opcional	Uso por consulta o tokens.	Solo utiliza resultados del motor y puede excluirse sin afectar la solución.

Al finalizar el discovery técnico podrá confirmarse al 100% qué servicios están autorizados, cuáles ya existen en el entorno de Super Naturista y cuáles deberán habilitarse para el inicio del desarrollo e implementación del proyecto. La tabla anterior presenta los servicios de referencia requeridos para cubrir conectividad, seguridad, almacenamiento, procesamiento, consulta, visualización y control; sin embargo, la selección final deberá alinearse con las políticas internas de TI, capacidades disponibles en Azure y decisiones de habilitación de Super Naturista.